

三平台自动化流程完整性分析与人工干预机制

文档类型： 流程完整性评审 + 机制设计
适用对象： 算法 / 软件 / IT / 项目负责人
版本： v1.0
日期： 2026-07-08
涉及平台： V821 / V861 (自研 NPU) / V853 (芯原 NPU)

1. 总评

现有自动化流程不齐全。最大缺口：

- 1. 缺“平台维度”（V821/V861/V853 工具链完全不同）
- 2. 缺“人工干预进入/退出”的机制化设计
- 3. 缺多个关键分支、出口和回环

****流程应拆成“平台无关主干”和“平台相关子流程”两层。****

2. 缺失清单（按流程段）

2.1 入口段

缺失项	不做的后果
Case 标准化入库（含平台型号 V821/V861/V853）	后续分析建立在不完整信息上
复现性确认	不能复现的 case 不应直接进分析
版本对齐检查（客户版本 vs 内部最新）	很多 problem 新版本已修复，白白走全流程

2.2 分析段

缺失项	说明
浮点 vs 板端一级分流（含平台维度）	只在 V853 异常 → 芯原工具链；三平台都有 → 浮点/数据问题
量化诊断分层深入	应自动逐层对比 → 定位 问题层 → 再转人工，而非直接“排查量化” top-N
“不值得修/不修”出口	超范围/数据不足/修复代价大/配置规避

2.3 数据与训练段

缺失项	说明
预标注 → 规则质检 → 人工修正（三步）	不能直接 YOLOv8s 自动标注进训练
训练数据集版本管理	无法回溯“哪个数据导致误检”
回归测试门禁	历史问题集+专业测试集，不通过不允许往下走

2.4 转换与部署段（多平台影响最大）

缺失项	说明
平台分发扇出节点	一个浮点模型→按平台清单分别进入子流程
各平台差异化子流程	V821/V861/V853 步骤、失败模式、责任人不同
混合量化决策节点	自动分析→人工确认配置→自动重新量化
板端性能验证	帧率/内存/功耗，三平台算力不同

2.5 交付段

缺失项	说明
内部审批后再交付	不应直接 release 给客户
按平台交付物清单	模型格式/SDK/配置/文档各不同
客户反馈闭环闭合	客户确认解决/未解决回写 case 库

3. 三平台子流程差异

3.1 架构：主干 + 平台适配器

平台无关主干（做一次，三平台共用）：

- case 入库、标准化、复现确认
- 浮点推理与基准结果
- 问题分诊
- 数据筛选、标注、质检
- 浮点模型训练与回归门禁
- 报告与历史 case 库

平台相关子流程（每平台一套适配器）：

接口	V821	V861（自研）	V853（芯原）
模型转换	截断 + 预编译参数	自研工具链	Acuity/芯原工具链
量化	PTQ + QAT（QAT 回环到训练）	自研量化	芯原量化
精度比对	逐层 dump + 比对	自研 dump（可控性最高）	依赖芯原比对能力
板端执行	V821 板集群	V861 板集群	V853 板集群
失败上报	内部工具组	内部 NPU 团队	芯原外部支持（周期不可控）

3.2 各平台特殊注意

V821：

- 流程最长：截断 → PTQ → QAT → 预编译
- **QAT 是回环到训练环节**，不是转换步骤

V861（自研 NPU）：

- 逐层 dump 接口最可控，**量化诊断自动化 ROI 最高，建议先做试点**

- 工具链不成熟时需“工具链 bug 上报”出口

V853（芯原 NPU）：

- 黑盒程度最高，工具链问题走外部支持
- 流程需“外部依赖等待”状态，不能堵死流水线

3.3 人月影响

三平台下板端/转换适配增加 +1.5~3 人月（第二、三平台各约 0.5~1.5 人月，V853 不确定性最大）。

4. 人工干预机制设计

4.1 核心原则

****人工干预 = 任务状态机 + 结构化决策表单，不是流程断掉线下沟通再手工重启。****

4.2 状态机



流程引擎暂停在断点，上下文全部保留，人工做完从断点继续。

4.3 进入人工：三要素

（1）派单：明确给谁

触发场景	派给谁
浮点/板端不一致，逐层分析完成	该平台量化/工具链负责人
疑似标注策略问题	算法负责人
数据质量差/无法复现	项目接口人
板端跑测失败（环境类）	软件/嵌入式值班
V853 工具链疑似 bug	芯原接口人
达标审批	算法 + 软件双负责人

（2）证据包：人工 5~10 分钟能判断

- case 基本信息 + 历史相似 case
- 浮点/量化/板端结果并排可视化
- 逐层比对报告（如适用）
- 自动分析初步结论

- 系统建议的候选选项

(3) 通知与超时升级

- 企业微信/钉钉/邮件推送
- SLA: 24h 未处理提醒, 48h 升级主管

4.4 四类人工决策表单

表单 1: 分诊确认

- ☐ 确认量化/转换问题 → 进入平台量化排查
- ☐ 确认浮点模型问题 → 进入数据/训练路径
- ☐ 确认板端代码/配置问题 → 派给软件
- ☐ 版本不一致 → 生成版本核对回复
- ☐ 无法复现 → 生成客户补充信息清单
- ☐ 不予处理 (填理由) → 归档并生成客户答复

表单 2: 标注策略确认

- ☐ 按现有规则库标注 (选择规则集版本)
 - ☐ 新增规则 (填什么情况标/不标, 存入规则库)
 - ☐ 本批数据不合入 (填理由)
- 抽帧数量上限: ____ (默认 100)

人工新增规则沉淀进规则库, 系统越用越聪明。

表单 3: 混合量化决策

- 系统给出: 掉点 X%, top-5 敏感层清单
- ☐ 采纳系统推荐混合量化配置 → 自动重新量化
 - ☐ 手动调整层清单 → 自动重新量化
 - ☐ 判定需要 QAT → 自动创建 QAT 训练任务 (回环到训练)
 - ☐ 判定工具链问题 → 生成问题单 (V861 内部 / V853 芯原)

表单 4: 发布审批

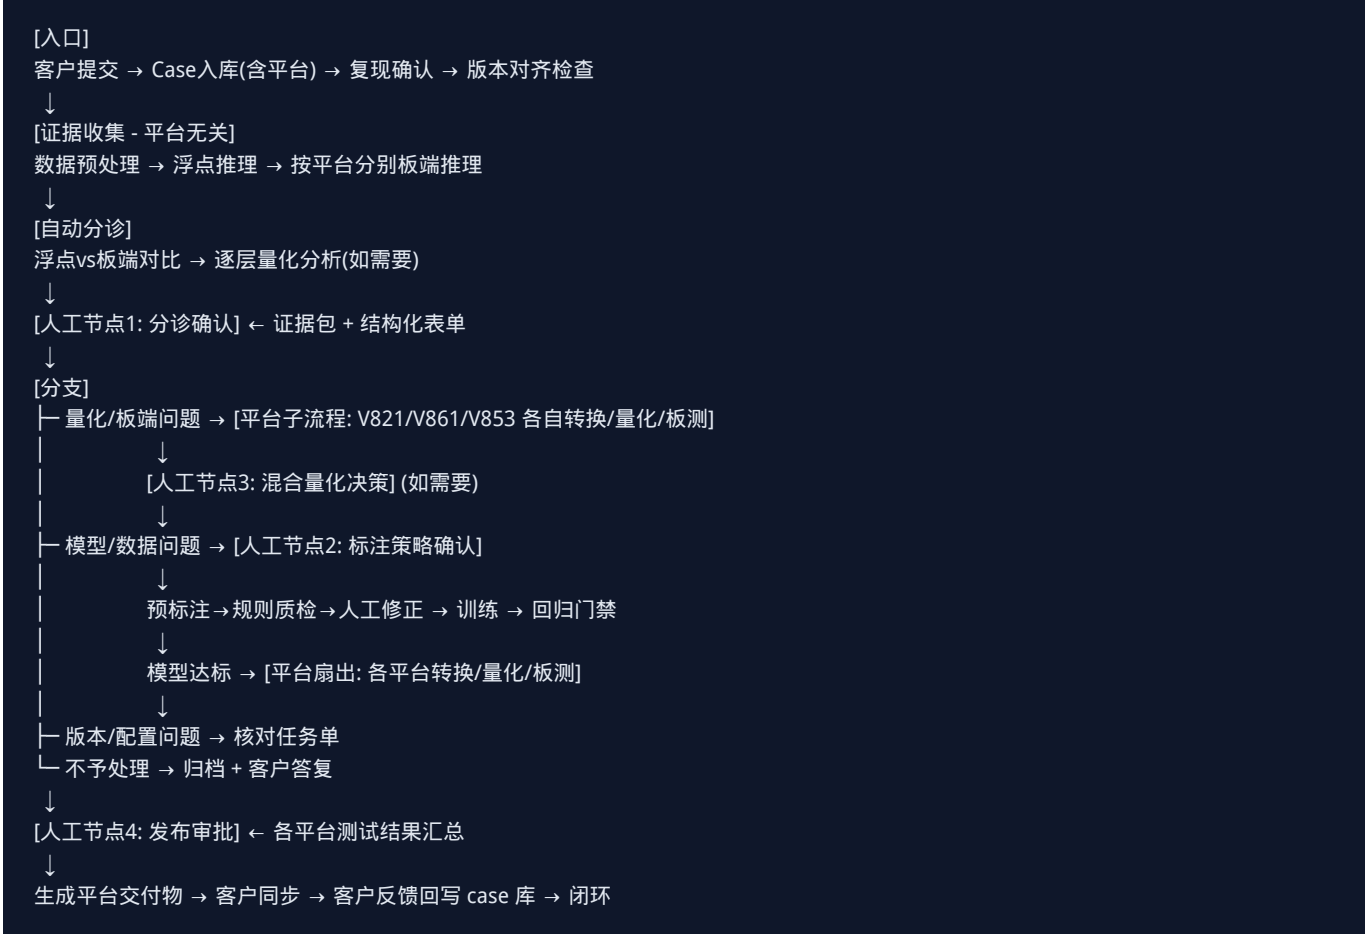
- 系统给出: 修复 case 列表、回归对比、各平台板端指标
- ☐ 批准发布 (选择平台: V821 / V861 / V853)
 - ☐ 驳回 (选原因 + 退回到哪个环节)

4.5 回到自动化: 决策即触发

人工决策	系统自动动作
进入数据/训练路径	创建数据筛选任务, 带 case 上下文
采纳混合量化配置	带配置重跑量化和精度评估
批准发布 V821	打包 V821 交付物、生成文档、更新 case 状态
新增标注规则	存入规则库, 下次类似 case 自动应用

同时记录: 谁、什么时间、看了什么证据、做了什么决策 (审计 + 未来智能推荐训练数据)。

5. 完整流程骨架（含三平台 + 人工节点）



6. 落地建议（6 条）

- 1. 流程图增加“平台”泳道，主干平台无关，转换/量化/板测按平台走子流程
- 2. V821 子流程画出 QAT 回环（回到训练，不是直线）
- 3. V853 子流程画“外部依赖等待”状态
- 4. V861 优先做逐层 dump 自动比对（ROI 最高）
- 5. 第一期人工节点只做 4 个：分诊确认、标注策略、混合量化、发布审批
- 6. 每个人工节点必须“派单 + 证据包 + 结构化表单 + 自动恢复”四件套

7. 结论

维度	结论
流程完整性	不齐全，需补入口/分析/训练/转换/交付各段缺失项
多平台	必须主干+适配器架构，不能画一条线
人工干预	状态机 + 证据包 + 结构化表单 + 决策触发自动化
第一期	4 个人工节点 + V861 量化诊断试点 + 闭环 A 分诊